

2 차 단위프로젝트 데이터 파트

최근 30 일의 플레이 기록을 바탕으로 향후 14 일 동안 게임을 하지 않을 사용자를 예측한다. 이탈은 회원 탈퇴나 미접속이 아니라, 정해진 게임 모드에서 관측 가능한 경기 기록이 14 일 동안 없는 상태로 정의한다.

-> 이 부분에서 이탈 정의 어떻게 할지 논의 한번 해봐야 할 듯

1 예측 목표와 설계

항목	설계 내용
프로젝트 목적	플레이 감소, 성적 변화, 이용 패턴을 분석하여 향후 비활동 가능성 예측
분석 단위	사용자 PUUID × 예측 기준일
분석 대상	기준일 이전 30 일 동안 대상 모드에서 1 경기 이상 플레이한 사용자
관측 기간과 예측 기간	기준일 이전 30 일을 입력으로 사용하고, 이후 14 일을 정답 판정에 사용
이탈 라벨	향후 14 일 대상 경기 0 건이면 churn_14d = 1, 1 건 이상이면 0
모드 범위	일반, 솔로랭크, 자유랭크, 칼바람 등 포함 모드를 사전 확정. 솔로랭크만 수집하면 솔로랭크 이탈로 표현
입력과 출력	입력: 활동량, 플레이 감소율, 승률, 연패 등 출력: 14 일 비활동 확률, 위험 등급, 주요 영향 변수
비교 모델	Logistic Regression 을 기본 모델로 두고 Random Forest, LightGBM, CatBoost 비교
학습 데이터	경기 기록을 사용자와 기준일별로 집계하여 한 행에 해당 시점의 상태 저장
검증 방법	과거 기준일로 학습하고 이후 기준일로 검증 및 테스트. 관측 기간과 라벨 기간의 중첩 관리
평가 지표	PR-AUC, ROC-AUC, Recall, Precision, F1. 확률 표시 시 확률 보정 확인
예측 예시	최근 7 일 플레이가 감소한 사용자의 향후 14 일 비활동 확률 표시. 실제 확률은 학습 후 산출

-> 이탈이라고 할 기준 설정

-> 7 일, 14 일, 30 일 기준의 이탈률과 성능을 비교하여 타당성을 점검

-> gameEndTimestamp 는 경기 종료 시각이며 마지막 로그인 시각이 아님...ㅏ

2 필요한 데이터

Match-V5의 경기 목록과 경기 상세 정보를 중심으로 수집
사용자 검색은 Riot ID를 PUUID로 변환하는 방식으로 구성
실제 수집 시 API 응답에서 필드 제공 여부와 누락을 확인

구분	원본 필드 또는 데이터	활용 및 우선순위
사용자·경기 식별	puuid, matchId	사용자별 연결과 중복 제거 / 필수
경기 시각	gameStartTimestamp gameEndTimestamp	활동일, 경기 간격, 마지막 경기 계산 / 필수
경기 시간	gameDuration	누적 및 평균 플레이 시간 / 필수
게임 모드	queueId	대상 모드 구분과 모드 전환 분석 / 필수
경기 결과	win	승률, 연승, 연패 계산 / 필수
전투 성적	kills, deaths, assists	평균 KDA, 데스, 성적 변화 / 필수
챔피언	championId, championName	다양성과 주력 챔피언 집중도 / 필수
포지션	teamPosition	주 포지션과 포지션 변경 비율 / 권장
골드	goldEarned	분당 골드와 성장 지표 / 권장
CS	totalMinionsKilled neutralMinionsKilled	분당 CS 계산 / 권장
피해량	totalDamageDealtToChampions	분당 챔피언 피해량 / 권장
시야	visionScore wardsPlaced, wardsKilled	시야 활동 분석 / 선택
항복·조기 종료	gameEndedInSurrender gameEndedInEarlySurrender	항복 비율과 조기 종료 처리 / 선택
버전	gameVersion	패치별 이용 및 성능 변화 / 권장
랭크 정보	티어, 랭크, LP, 수집 시각	티어별 분석. 과거 시점 자료 별도 저장 / 선택
수집 관리	요청 상태, 조회 기간, 페이지 처리 완료 여부, 수집 시각	수집 실패와 비활동 구분 / 필수
미래 경기 유무	기준일 이후 14일 대상 경기 기록	라벨 생성 전용. 모델 입력 제외 / 필수

중복 제거 기준: 사용자 목록은 PUUID, 경기 참여 기록은 (PUUID, matchId) 조합임. 경기 데이터를 사용자당 한 건으로 줄이면 플레이 변화 분석이 불가능

3 생성해야 하는 변수

모든 입력 변수는 예측 기준일 이전 데이터로만 계산

7 일은 최근 7 일, 직전 7 일은 그보다 앞선 7 일을 뜻함

-> 어떤 식으로 분석 할건지랑 어떤 변수가 필요한지도 논의 해봐야 할 듯

분류 및 변수	계산 방법	분석 의미
최근 활동 days_since_last_game	기준일 - 마지막 경기 종료 시각을 일 단위로 변환	마지막 경기 이후 휴식 기간
이용량 games_7d, games_30d	최근 7 일 및 30 일 경기 수	이용 빈도
활동일 active_days_7d active_days_30d	최근 7 일 및 30 일 중 경기가 있었던 날짜 수	이용의 꾸준함
이용 강도 games_per_active_day	30 일 경기 수 ÷ 30 일 활동일 수	활동한 날의 플레이 강도
플레이 시간 playtime_hours_7d playtime_hours_30d	해당 기간 경기 시간 합계 ÷ 3,600 경기 시간은 초 단위 기준	게임에 사용한 시간
이용량 변화 games_change_rate	(최근 7 일 경기 수 - 직전 7 일 경기 수) ÷ max(직전 7 일 경기 수, 1)	플레이 급감 여부
활동일 변화 active_days_change	최근 7 일 활동일 수 - 직전 7 일 활동일 수	이용하는 날의 감소
경기 간격 avg_gap_hours max_gap_hours	연속 경기의 이전 종료부터 다음 시작까지 간격의 평균과 최대값	플레이 간격의 증가
승률 win_rate_7d, win_rate_30d	해당 기간 승리 수 ÷ 경기 수	최근 승패 경험
승률 변화 win_rate_change	최근 7 일 승률 - 직전 7 일 승률	성적 악화 여부
최근 연패 current_loss_streak	기준일 직전 경기부터 역순으로 센 연속 패배 수	최근 연패 상태
최대 연패 max_loss_streak_30d	30 일 중 가장 긴 연속 패배 횟수	반복적 패배 경험
전투 성적 avg_kda, avg_deaths	경기별 (킬+어시스트) ÷ max(데스, 1)의 평균 및 평균 데스	경기 수행 지표

분류 및 변수	계산 방법	분석 의미
성적 변화 kda_change	최근 7 일 평균 KDA - 직전 7 일 평균 KDA	최근 수행 지표 악화
성장·기여 gold_per_min, cs_per_min damage_per_min	경기별 골드, CS, 챔피언 피해량을 경기 시간(분)으로 나눈 뒤 평균	경기 길이를 보정한 성적
챔피언 다양성 unique_champions_30d	30 일 동안 사용한 챔피언 종류 수	플레이 다양성
챔피언 집중도 main_champion_ratio	최다 사용 챔피언 경기 수 ÷ 전체 경기 수	특정 챔피언 집중 정도
포지션 일관성 main_position_ratio	주 포지션 경기 수 ÷ 유효 포지션 경기 수	주 포지션 유지 정도
모드 구성 ranked_ratio, aram_ratio	해당 모드 경기 수 ÷ 전체 경기 수	이용 모드 선호
모드 전환 ranked_ratio_change	최근 7 일 랭크 비중 - 직전 7 일 랭크 비중	랭크 중단과 모드 변경 구분
이용 시간대 night_game_ratio weekend_game_ratio	한국 시간 기준 심야 및 주말 경기 비율. 심야 구간 사전 정의	시간대별 이용 특성
항복 경험 surrender_ratio	항복으로 종료된 경기 수 ÷ 전체 경기 수	항복 경험과 이탈의 관계
정답 churn_14d	미래 14 일 경기 0 건이면 1, 그 외 0	예측 대상이며 입력에서 제외

경기가 없는 기간의 승률은 0% 대신 결측값으로 처리하고 경기 수를 함께 사용

경기가 2 건 미만이면 경기 간격을 계산 X

포지션과 분당 성적은 게임 모드별 차이를 고려

4 분석해야 하는 부분

분석 주제	핵심 질문과 분석 방법	결과 활용
데이터 품질	결측률, 중복 건수, 기간별 수집 완료율 확인	라벨 신뢰도 확보
이탈 비율	유지·이탈 비율을 막대그래프로 비교	클래스 불균형 확인
이탈 기준	7 일, 14 일, 30 일 기준별 이탈률과 성능 비교	정의의 타당성 검토
활동량과 이탈	경기 수와 감소율 구간별 이탈률 비교	활동 변수 검증
이용 주기	활동 요일과 경기 간격별 이탈률 비교. 주말 이용자의 오분류 확인	규칙적 저빈도 이용 반영
패배와 이탈	연패 길이, 승률 변화 구간별 이탈률 비교	성적 변수 검증
모드별 차이	랭크 감소 후 다른 모드 이용 여부와 비중 변화 분석	모드 이탈과 전체 비활동 구분
챔피언·포지션	집중도 구간별 이탈률 및 이용 패턴 비교	사용자 유형별 특성 파악
성적 비교	모드·포지션별 KDA 와 분당 지표 비교	플레이 환경 차이 반영
사용자 유형	활동량, 규칙성, 선호 모드 기준 그룹별 비교	유형별 리포트 구성
변수 중복	상관관계 히트맵과 변수 제외 전후 성능 비교	불필요한 변수 정리
모델 설명	변수 중요도 및 SHAP 으로 전체·개별 예측 설명	모델 판단 근거 제공
오분류	실제 유지인데 위험군으로 분류한 FP 와 이탈을 놓친 FN 사례 비교	분류 임계값과 변수 개선
표본 편향	수집 경로, 활동량, 티어별 표본 분포 확인	결과의 적용 범위 명시

연패와 이탈이 함께 나타나더라도 연패가 이탈의 원인이라고 단정 X

SHAP 은 모델 판단에 대한 설명이며 실제 이탈 원인의 증명은 아님

5 웹 화면 구성 요소

-> 대략적인 거간 한데 대시보드 어떤식으로 구성할지도 논의 해봐야함

화면	구성 요소	표시 정보와 기능
메인 대시보드	KPI 카드, 활동 추세, 위험도 분포	분석 사용자 수, 평균 예측 확률, 고위험 사용자 수, 주간 경기 수
사용자 검색	Riot ID, 서버 선택, 분석 버튼	사용자 조회, 데이터 수집 진행 및 완료 상태
개인 분석 요약	확률, 위험 등급, 기준일	향후 14 일 비활동 가능성, 대상 모드, 데이터 기준 시각
개인 플레이 패턴	일별 경기 수, 활동 캘린더, 승률 추세	30 일 활동 및 최근 7 일 변화
개인 예측 근거	주요 영향 변수 3~5 개	경기 수 감소, 활동 간격 증가 등 예측에 영향을 준 항목
사용자 비교	동일 활동량·모드 그룹 비교	경기 수, 승률, 연패, 활동일 수 비교
전체 사용자 목록	위험도 필터, 정렬, 검색	사용자 식별자, 확률, 최근 경기일, 최근 경기 수
이탈 요인 분석	변수 선택, 구간별 이탈률, SHAP	비활동과 관련된 특징 탐색
모델 성능	비교표, 혼동행렬, PR 곡선	Precision, Recall, F1, PR-AUC, 분류 임계값
데이터 안내	기간, 범위, 수집 누락 표시	이탈 정의, 수집 범위, 분석 한계

위험 등급의 구분 기준은 검증 데이터의 Precision 과 Recall 을 확인한 뒤 결정

수집이 불완전하거나 입력 데이터가 부족한 경우에는 예측 확률 대신 분석 불가 또는 데이터 부족 상태를 표시

주요 산출물 : 인공지능 데이터 전처리 결과서, 인공지능 학습 결과서, 학습된 인공지능 모델

초기 구현 범위

활동량, 활동 감소, 승패 중심의 모델을 먼저 구현

웹은 메인 대시보드, 개인 분석, 모델 성능 화면부터 완성한 뒤 모드 전환과 사용자 그룹 비교

6 학습 데이터 구성과 검증 기준

주의점	적용 방법
미래 정보 유입 방지	기준일 이후 경기 수, 승률, 마지막 경기 시각은 라벨 생성에만 사용한다.
미완료 관측 제외	기준일 이후 14 일을 전부 확인할 수 있는 데이터만 학습 정답을 확정한다.
API 실패 구분	조회 실패나 페이지 미완료는 미확인으로 처리하고 재수집한다. 이를 이탈로 분류하지 않는다.
기간 전체 수집	최근 몇 경기만 수집하지 않고 고활동 사용자도 관측 기간 전체가 포함되도록 페이지 처리한다.
모집 편향 관리	가능한 과거 기간의 경기에서 사용자를 확보하고 미래 활동 여부와 무관하게 추적한다. 현재 활동 사용자만 모집했을 때의 한계를 명시한다.
시간순 검증	학습 라벨 기간이 검증 시점과 겹치지 않게 조정한다. 같은 사용자의 여러 기준일을 무작위로 섞지 않는다.
신규 사용자 평가	신규 사용자에 대한 일반화가 목적이면 PUUID 를 분리한 평가를 별도로 수행한다.
랭크 시점 일치	현재 티어를 과거 기준일에 붙이지 않는다. 당시 저장된 티어만 사용하거나 초기 모델에서 제외한다.
전처리 누수 방지	결측값 처리, 인코딩, 스케일링 등은 학습 데이터에서 학습한 규칙을 검증·테스트에 적용한다.

구현 순서

① 대상 모드와 이탈 기준 확정 → ② PUUID 및 경기 기록 수집 → ③ 품질 검사와 중복 제거 → ④ 사용자·기준일별 변수 생성 → ⑤ 미래 14 일 라벨 생성 → ⑥ EDA → ⑦ 시간순 모델 학습과 평가 → ⑧ 웹 화면 연결